

Кейс от Yandex.Cloud // Прототип для пакетной обработки выписных эпикризов и преобразования неструктурированного медтекста в JSON

Роли

Разработчик / data engineer
Специалист по NLP/ML
Аналитик или QA
Медицинский эксперт

Навыки

- Python
- NLP
- LLM

Компания-кейсодаватель

Центр технологий для общества YandexCloud — Реализуем социально значимые проекты в области образования и науки, здравоохранения, экологии и культуры. Объединяем технологии, экспертов и исполнителей, чтобы быстрее и эффективнее решать важные для общества задачи.

Описание проблемы

Чтобы изучать результаты лечения и качество медицинской помощи, исследователям нужно сопоставлять сведения из множества медицинских документов. Пока эти сведения остаются в свободном тексте, их трудно искать, сравнивать и анализировать вместе. Перенос данных вручную занимает время специалистов, а различия в формулировках и сокращения усложняют работу.

Решение помогает автоматически находить нужные сведения в медицинских документах и переносить их в структурированные поля. После проверки специалистом такие данные можно использовать в исследованиях. Это снижает объём рутинной работы врачей и исследовательских команд и помогает быстрее получать знания, необходимые для улучшения медицинской помощи.

В этом кейсе такой подход применяется к кардиологическим выписным эпикризам пациентов, перенёсших острый коронарный синдром (ОКС). Все документы синтетические. Решение предназначено для исследовательского и демонстрационного использования и не должно применяться для постановки диагноза или принятия клинических решений.

Ожидаемое решение

Работающий MVP для пакетной обработки документов: на каждый входной эпикриз создаётся валидный JSON со всеми обязательными группами и полями, значениями и подтверждающими фрагментами текста.

Что нужно сделать

Вам предстоит извлечь из синтетических кардиологических выписных эпикризов пациентов, перенёсших ОКС, 50 кардиологических признаков о госпитализации, диагнозе, обследованиях и назначениях. Можно использовать любые методы извлечения. В пакет участника входят 100 открытых документов; ещё 1000 документов организаторы применят для контрольной проверки.

Что предоставить

Для каждого обработанного документа из контрольной выборки передайте отдельный файл JSON с тем же базовым именем: например, `train-0001.md` → `train-0001.json`. Структура каждого файла: девять групп, внутри каждой — перечисленные ниже ключи и строковые значения. Образец структуры — `participant-output-template-50.json`. Все файлы должны лежать в папке `result` в корне репозитория.

Единые правила записи

- Даты — ДД.ММ.ГГГГ, без времени. Числа — без единиц измерения, десятичная точка. Давление — верхнее/нижнее, например 140/90.
- Если обычное значение не найдено, пишите «не указано». Не вычисляйте заново явно не записанные показатели, например ИМТ.
- Для бинарных кодов 1 означает прямое указание признака, 0 — явное отрицание либо отсутствие упоминания по кодовому правилу. 0 не является медицинским заключением об отсутствии болезни.
- При нескольких измерениях лабораторного показателя берите первый результат текущей госпитализации. Для давления и пульса нужен первичный осмотр, для ЭКГ — отдельная запись ЭКГ.
- Для коронарографии Y — выполнена, R — документирован отказ, N — сведений нет. Значения сосудов 0/1/2 указываются только при выполненной коронарографии: 0 — сужение менее 50%, 1 — 50–89%, 2 — 90% и более либо окклюзия. Без исследования — «не указано».

Проверка результата

Организаторы сравнят ваши JSON-файлы с эталонной разметкой для тех же документов. Оцениваются корректность структуры, полнота и совпадение значений по полям и группам. Контрольные документы и эталонные ответы в пакет участника не входят.

Целевая аудитория решения

Медицинские аналитики, операторы регистров, исследовательские команды и специалисты, которые готовят данные для анализа. Кейс не является системой поддержки клинических решений.

Ограничения и риски

- Неоднозначные формулировки, отрицания, несколько дат или измерений, пропуски, нестандартные сокращения.
- Генерация неподтвержденных значений и нарушение JSON-контракта.
- Ограниченное время хакатона.
- Все данные синтетические; решение не должно применяться для постановки диагноза или принятия клинических решений.
- Передавать реальные медицинские документы в решение в рамках хакатона нельзя.

Конкуренты решения

Не является обязательной частью кейса. Команда может сравнить свой подход с классами решений: правила/шаблоны, классические NLP-модели, большие языковые модели и гибридные конвейеры

Критерии оценки решения

- Валидность JSON.
- Полнота документов и полей.
- Качество категориальных и числовых значений.
- Качество извлечения текстовых фрагментов.
- Подтверждаемость значений.
- Воспроизводимость запуска.
- Скорость.
- Понятность демонстрации.

В процессе разработки решения ориентируйтесь на критерии оценки – это поможет вам структурировать работу и убедиться, что ваш продукт соответствует ожиданиям кейсодателя и требованиям хакатона.

Напоминаем, что в течение хакатона у вас есть возможность обратиться за консультацией к наставнику: используйте эту возможность, чтобы уточнить детали, обсудить идеи и получить обратную связь по технической и пользовательской части решения.